

Sprawozdanie z zagadnienia nr4.

Opis syntetyczny:

Reguła Hebba jest jedną z popularnych metod samouczenia sieci neuronowych.

Zasada działania polega na tym, że sieci przedstawia się kolejne przykłady sygnałów wejściowych, jednak nie mówi się informacji co z tymi sygnałami zrobić. Sieć odbiera różne sygnały i obserwuje otoczenie. Na podstawie napływających danych sieć dedukuje jakie mają one znaczenie i ustala zachodzące między nimi zależności.

**Ogólna reguła Hebba** mówi, że zmiany wag powinny odbywać się według reguły

$$\Delta \mathbf{w}(k) = F(\mathbf{x}(k), y(k)),$$

czyli ogólnie, że przyrost wag  $\Delta \mathbf{w}(k)$  powinien zależeć zarówno od wielkości wzorca presynaptycznego  $\mathbf{x}(k)$  jak i od wytworzonego wzorca postsynaptycznego  $y(k)$ .

**Prosta reguła Hebba:** (stała  $\eta$  oznacza tu współczynnik proporcjonalności):

$$\Delta \mathbf{w}(k) = \eta \cdot \mathbf{x}(k) \cdot y(k).$$

Jednak ta reguła była zbyt uproszczona. Przy wielokrotnej prezentacji tego samego wzorca wagi wzrastały wykładniczo. Po każdej prezentacji wzorca  $\mathbf{x}(k)$  wektor wag był przesuwany w kierunku tego wzorca, mogło to powodować raptowne i dość znaczne zmiany wyuczonego dotychczas wektora wag.

**Modyfikacja (1)** - wprowadzenie współczynnika zapominania  $b$

$$\Delta w_{ij}(k) = c x_j(k) y_i(k) - b w_{ij}(k) y_i(k)$$

- dobór współczynnika  $b$  jest kluczowy dla zapewnienia stabilności procesu i zależy od konkretnego problemu, powstrzymuje niekontrolowany wzrost wartości wag.

**Modyfikacja 2 (Oja)**

$$\Delta w_{ij}(k) = c y_i(k) [x_j(k) - y_i(k)] w_{ij}(k)$$

- wprowadza samonormalizację wektora wag w każdym kroku uczącym
- w stanie ustalonym  $\|\mathbf{W}\|=1$

## Dane uczące:

Wygenerowane zostały matryce w rozmiarze 15x15 dla 4 emotikon: śmiech, płacz, miłość, całus.

Przykładowa matryca:

```
-1 -1 -1 -1 -1 -1 -1 -1 -1 -1 -1 -1 -1 -1 -1
-1 -1 -1 -1 -1 1 1 1 1 1 -1 -1 -1 -1 -1
-1 -1 -1 1 1 -1 -1 -1 -1 -1 1 1 -1 -1 -1
-1 -1 1 -1 -1 -1 -1 -1 -1 -1 1 -1 -1 -1
-1 -1 1 -1 1 -1 -1 -1 -1 1 -1 1 -1 -1
-1 1 -1 1 -1 -1 -1 -1 -1 -1 1 -1 1 -1
-1 1 -1 -1 1 1 1 -1 1 1 1 -1 -1 1 -1
-1 1 -1 -1 1 -1 -1 -1 -1 -1 1 -1 1 -1
-1 1 -1 1 1 -1 -1 -1 -1 -1 1 1 -1 1 -1
-1 1 1 1 -1 1 1 1 1 1 1 1 1 -1
-1 -1 1 1 -1 1 1 1 1 1 -1 1 1 -1 -1
-1 -1 1 -1 -1 1 1 1 -1 -1 -1 1 -1 -1
-1 -1 -1 1 1 -1 -1 -1 -1 -1 1 1 -1 -1 -1
-1 -1 -1 -1 1 1 1 1 1 -1 -1 -1 -1 -1
-1 -1 -1 -1 -1 -1 -1 -1 -1 -1 -1 -1 -1 -1
```

Do testów używano zaszumionych matryc gdzie poprawność pojedynczych pikseli była na poziomie 60% i 80% względem oryginału.

## Zestawienie danych + przykładowe wydruki:


```
MSE: 2.66676e+144    MAPE: 1.63302e+73%
MSE: 4.1149e+144    MAPE: 2.02852e+73%
MSE: 4.95428e+144    MAPE: 2.22582e+73%
epoka: 201
MSE: 1.11882e+145    MAPE: 3.34487e+73%
MSE: 1.35005e+145    MAPE: 3.6743e+73%
MSE: 2.08317e+145    MAPE: 4.56418e+73%
MSE: 2.5081e+145     MAPE: 5.0081e+73%
epoka: 202
MSE: 5.66401e+145    MAPE: 7.52596e+73%
MSE: 6.83462e+145    MAPE: 8.26717e+73%
MSE: 1.05461e+146    MAPE: 1.02694e+74%
MSE: 1.26973e+146    MAPE: 1.12682e+74%
epoka: 203
MSE: 2.86741e+146    MAPE: 1.69334e+74%
MSE: 3.46002e+146    MAPE: 1.86011e+74%
MSE: 5.33894e+146    MAPE: 2.31061e+74%
MSE: 6.42799e+146    MAPE: 2.53535e+74%
epoka: 204
MSE: 1.45162e+147    MAPE: 3.81002e+74%
MSE: 1.75164e+147    MAPE: 4.18526e+74%
MSE: 2.70284e+147    MAPE: 5.19888e+74%
MSE: 3.25417e+147    MAPE: 5.70454e+74%
```

Przykładowy zrzut wykonany w trakcie wykonywania procesu uczenia, na którym widnieje błąd MSE i MAPE.

Dane uzyskane :

### 1) Bez współczynnika zapominania

| Bez współczynnika zapominania |                                  |          | Emotikona |        |       |        |
|-------------------------------|----------------------------------|----------|-----------|--------|-------|--------|
|                               | rodzaj i %podobienstwa do wzorca | Nr Epoki | placz     | miłość | całus | śmiech |
|                               | test_placz80%                    | 230      | 77        | 68     | 73    | 70     |
|                               | test_miłość60%                   | 231      | 73        | 90     | 72    | 68     |
|                               | test_całus60%                    | 238      | 71        | 70     | 79    | 74     |
|                               | test_śmiech80%                   | 231      | 82        | 75     | 83    | 92     |




Przy współczynniku uczenia = 0,5 proces uczenia trwał około 233 epoki. Dla zniekształconych emotikon testowych, sieć rozpoznała wszystkie obrazy poprawnie.

Bez współczynnika zapominania

| I.r=0,75 |                    |          | Emotikona |        |       |        |
|----------|--------------------|----------|-----------|--------|-------|--------|
|          | rodzaj i %podobien | Nr Epoki | placz     | miłość | całus | śmiech |
|          | test_placz80%      | 208      | 78        | 70     | 73    | 72     |
|          | test_miłość60%     | 213      | 75        | 90     | 72    | 64     |
|          | test_całus60%      | 209      | 73        | 75     | 78    | 74     |
|          | test_śmiech80%     | 215      | 85        | 78     | 82    | 90     |
|          |                    | 211,25   |           |        |       |        |

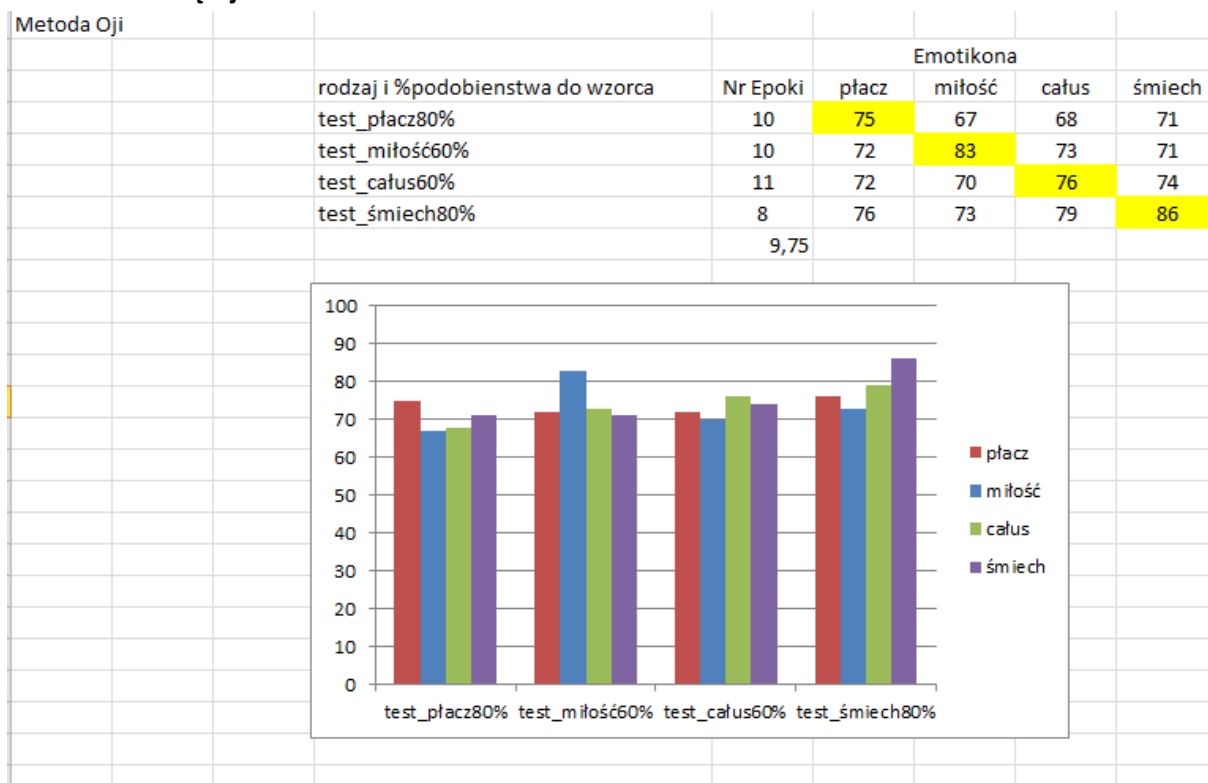
Dla porównania zwiększony współczynnik uczenia =0,75, który przyspieszył proces uczenia o około 22 epoki.

## 2) Ze współczynnikiem zapominania



Przy współczynniku uczenia=0,5 i współczynniku zapominania =0,05 czas uczenia trwał ok. 172 epoki. Rozpoznano wszystkie obrazy poprawnie, choć jak widać z inną dokładnością.

## 3) Uczenie metodą Oji

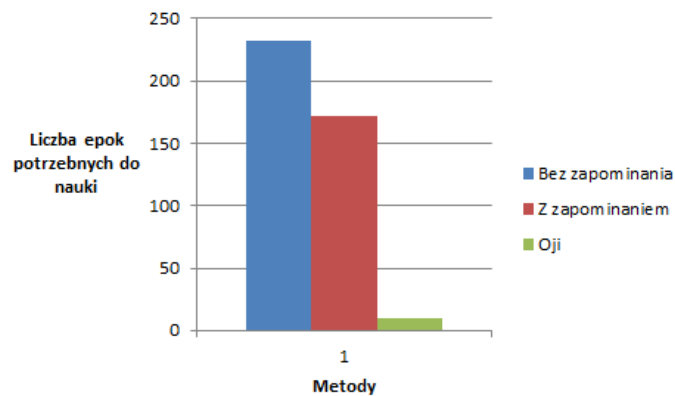


Przy współczynniku uczenia =0,5 sieć metoda Oji uczyła się w ok. 10 epok. Obrazy zostały rozpoznane poprawnie szybciej lecz z mniejszą precyzją.

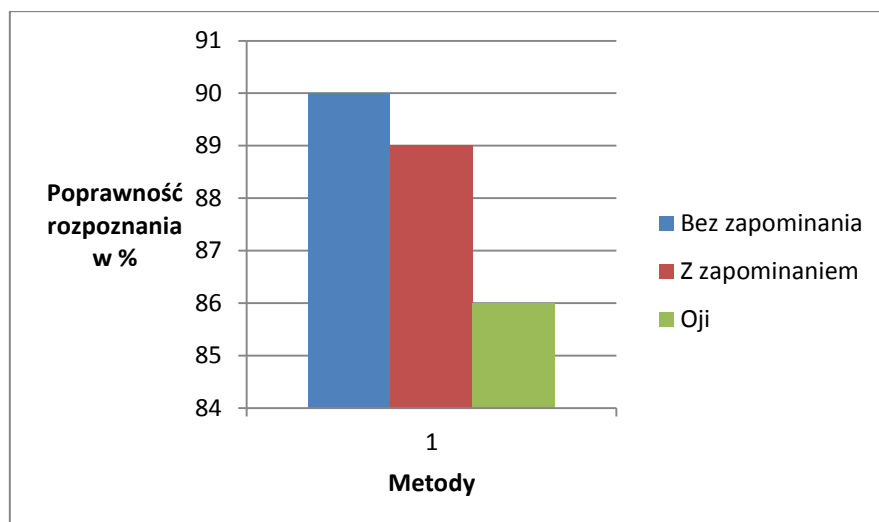
### Zestawienie wyników:

Porównanie prędkości uczenia sieci w zależności od wybranej metody uczenia.

| Metoda          | I.epok |
|-----------------|--------|
| Bez zapominania | 232,5  |
| Z zapominaniem  | 172    |
| Oji             | 9,75   |



Zestawienie dokładności rozpoznawania obrazów w zależności od wybranej metody.



### Wnioski:

- Metoda Hebba polega na wzmacnianiu połączeń między źródłami silnymi i osłabieniu tych słabszych
- Modyfikacja tej metody w metodę Oji w znacznym stopniu przyspiesza proces uczenia się
- współczynnik zapominania ogranicza wzrost wektora wag (pozwala mieć nad nim kontrolę)
- wielkości współczynników uczenia i zapominania mają wpływ na szybkość i dokładność uczenia
- testy polegały na podaniu sieci zniekształconego obrazu i próbie jego rozpoznania

-metodą najszybszą okazała się być metoda Oji ,lecz najdokładniejszą metoda Hebba bez współczynnika zapominania

#### Listing kodu:

```
void
generateInput(){
    srand(time(NULL));
    int i, j, tmp;
    for (i = 0; i<SIZE; i++){
        tmp = rand() % 2 - 1;
        generowanie losowych danych uczacych
        if (tmp == 0) input(i) = 1;
        else input(i) = -1;
    }

    for (i = 0; i<SIZE; i++){
        generowanie zdeformowanych emotikon
        inputSmiech80pr(i) = vec_emoticons(i, 0);
        inputCalus60pr(i) = vec_emoticons(i, 1);
        inputMilosc80pr(i) = vec_emoticons(i, 2);
        inputPlacz60pr(i) = vec_emoticons(i, 3);
    }

    for (i = 0; i<45; i++){
        j = rand() % 225;
        inputMilosc80pr(j) = !inputMilosc80pr(j);
        j = rand() % 225;
        inputSmiech80pr(j) = !inputSmiech80pr(j);
    }

    for (i = 0; i<90; i++){
        j = rand() % 225;
        inputCalus60pr(j) = !inputCalus60pr(j);
        j = rand() % 225;
        inputPlacz60pr(j) = !inputPlacz60pr(j);
    }
}

void
generateWeights(){
    srand(time(NULL));
    int i;
    for (i = 0; i<SIZE; i++){
        w(i, 0) = (float)rand() / (float)RAND_MAX;
        losowanie wag
        w(i, 1) = (float)rand() / (float)RAND_MAX;
        losowanie wag
        w(i, 2) = (float)rand() / (float)RAND_MAX;
        losowanie wag
        w(i, 3) = (float)rand() / (float)RAND_MAX;
        losowanie wag
    }
}

int
main(){
```

```

int i, j;
int epoka = 0; // liczba epok

const double LEARNING_RATE = 0.5; /* współczynnik uczenia */
const double FORGET_RATE = 0.05; /* współczynnik zapominania */

double globalError = 0.; /* błędy */
double localError = 0.;
double MSE = 0.;
double MAPE = 0.;

double pom = 0.; /* zmienne pomocnicze */
double pomt = 0.;

zeruj(); /* ustawienie wartości domyślnych dla
wektora a */

//UCZENIE WG HEBBA
generateWeights(); /* wygenerowanie wag */
setLearnVectors(); /* ustawienie wektorów uczących */

do{
    cout << "epoka: " << epoka << endl;

    /* BEZ WSPÓLCZYNNIKA ZAPOMINANIA
    for (i = 0; i<4; ++i){
        globalError = 0.;
        for (j = 0; j<SIZE; ++j){
            pom = a(j);
            a(j) = (w(j, i)*vec_emoticons(j, i));
            w(j, i) = w(j, i) + LEARNING_RATE*a(j)*vec_emoticons(j, i);

            if (localError == abs(pom - a(j))) break;
            localError = abs(pom - a(j));
            globalError = globalError + pow(localError, 2);

        }

        MSE = pow(globalError, 2) / SIZE;
        MAPE = (globalError * 10) / SIZE;
        cout << " MSE: " << MSE << "\tMAPE: " << MAPE << "%\n";
    }*/

    // ZE WSPÓLCZYNNIKIEM ZAPOMINANIA
    for(i=0;i<4;++i){
        globalError = 0.;
        for(j=0;j<SIZE;++j){
            pom = a(j);
            a(j) = (w(j,i)*vec_emoticons(j,i));
            w(j,i) = w(j,i)*FORGET_RATE + LEARNING_RATE*a(j)*vec_emoticons(j,i);

            if(localError==abs(pom-a(j))) break;
            localError = abs(pom - a(j));
            globalError = globalError + pow(localError,2);
        }

        MSE = pow(globalError,2)/(SIZE);
        MAPE = (globalError*10/SIZE);
        cout << "i:" << i << " MSE: " << MSE << "\tMAPE: " << MAPE << "%\n";
    }

    // REGUŁA OJ1

```

```
        /*for(i=0;i<4;++i){  
        globalError = 0.;  
        for(j=0;j<SIZE;++j){  
            pom = a(j);  
            a(j) = (w(j,i)*vec_emoticons(j,i));  
            w(j,i) = w(j,i) + (LEARNING_RATE*a(j)*(vec_emoticons(j,i)-a(j)*w(j,i)));
```

```
        if(localError==abs(pom-a(j))) break;  
        localError = abs(pom - a(j));  
        globalError = globalError + pow(localError,2);  
        }
```

```
        MSE = pow(globalError,2)/(SIZE);  
        MAPE = (globalError*10/SIZE);  
        cout << "i:" << i << " MSE: " << MSE << "\tMAPE: " << MAPE << "%\n";  
    }*/
```

```
        epoka++;
```

```
    } while (globalError != 0 && epoka<1000);
```

```
    cout << "\nliczba epok: " << epoka << endl;
```

```
    test();
```

```
    return 0;
```

```
}
```